

The Databricks logo is displayed in white text on a solid olive green rectangular background.

Databricks




Databricks: Clusters Spark como servicio


La necesidad de Databricks

- La nube se convierte en la opción preferida
- El escenario de crear y destruir clusters a demanda se convierte en habitual para reducir costes
- Existe el hueco de una plataforma / servicio que sea capaz de gestionar los recursos de procesamiento, es decir, los clusters, independientemente de usuarios, notebooks, etc..
- Aparece Databricks
- Microsoft adquiere Databricks → Azure Databricks


Arquitectura



Posicionando opciones



Arquitectura de cluster Azure Databricks



Características

- Espacio de trabajo gestionado
- Control de acceso a varios niveles
- Dos tipos de cluster
 - Standard
 - Serverless
 - Autoconfiguración solo para SQL y Python por el momento
- Databricks File System (DBFS)

Demo 07 A Databricks DBFS



Entorno Databricks

DBFS

Bases de datos y tablas

- Una base de datos es una colección de tablas
- Las tablas en Databricks son equivalentes de los DataFrames Spark
- Dos tipos
 - Globales.
 - Disponibles para todos los clusters
 - Se registran en el metastore de Hive
 - Locales
 - Vistas o tablas temporales

Streaming Estructurado

- Soporte de Spark Streaming estructurado
- Mejoras de interfaz para revisión de consultas
- Posibilidad de tener ejecuciones en paralelo en el notebook



Revisión interactiva de datos

Generación de DataFrame de Streaming

Visualización

Databricks Delta

- Motor analítico por encima de Spark
- Ofrece
 - Transacciones ACID
 - Upserts eficientes
 - Mejora de rendimiento de streaming
 - Versionado de datos
 - Optimizaciones del motor de consultas



Creación de tablas Delta

Inserciones

Visualización de históricos

